

XAI Práctica 5: Partial Dependency Plot

Métodos *model-agnostic* aplicados a Random Forest

elsenyordata

09 de mayo de 2026

Índice

1. Introducción y metodología	2
1.1. Objetivo	2
1.2. Fundamento del PDP	2
1.3. Carga de paquetes	2
1.4. Función PDP genérica	2
2. Ejercicio 1 — PDP unidimensional: alquiler de bicicletas	4
2.1. Carga y preparación de datos	4
2.2. Entrenamiento del Random Forest	4
2.3. Cálculo de los PDP	4
2.4. Visualización	5
2.5. Análisis e interpretación	6
3. Ejercicio 2 — PDP bidimensional: humedad y temperatura	8
3.1. Muestra aleatoria	8
3.2. Cálculo del PDP 2D	8
3.3. Visualización	8
3.4. Distribución de las variables	10
3.5. Análisis e interpretación	10
4. Ejercicio 3 — PDP: predicción del precio de viviendas	11
4.1. Carga y muestreo aleatorio	11
4.2. Entrenamiento del Random Forest	11
4.3. Cálculo de los PDP	11
4.4. Visualización	12
4.5. Análisis e interpretación	13

5. Conclusiones generales	15
6. Información de la sesión	15

1. Introducción y metodología

1.1. Objetivo

Aplicar el método **Partial Dependency Plot (PDP)** a dos problemas de regresión resueltos mediante *Random Forest*, con el fin de **interpretar el comportamiento aprendido por el modelo** sin acceder a su estructura interna (enfoque *model-agnostic*).

1.2. Fundamento del PDP

Sea $\hat{f}$ un modelo entrenado y $\mathbf{x} = (x_S, x_C)$ el vector de entrada, donde x_S es el subconjunto de variables de interés y x_C las restantes. El PDP se define como:

$$\hat{f}_{x_S}(x_S) = \mathbb{E}_{x_C}[\hat{f}(x_S, x_C)] \approx \frac{1}{n} \sum_{i=1}^n \hat{f}(x_S, x_C^{(i)})$$

Es decir: para cada valor de x_S , se promedia la predicción del modelo manteniendo el resto de variables fijas en sus valores observados.

Limitación clave. El PDP asume independencia entre x_S y x_C ; cuando existen correlaciones fuertes, los valores promediados pueden corresponder a combinaciones poco realistas de variables. Por este motivo se acompañan los gráficos con la **distribución empírica** de las variables (alfombra inferior o rug).

1.3. Carga de paquetes

```
library(randomForest)
library(ggplot2)
library(dplyr)
library(gridExtra)
library(viridis)
```

1.4. Función PDP genérica

A continuación se implementa el algoritmo **manualmente** (en lugar de usar el paquete `pdp`) para mostrar de forma transparente el cálculo:

```
# PDP unidimensional.
# Para cada valor del grid se reemplaza la feature en todo el dataset
# y se promedian las predicciones del modelo.
compute_pdp <- function(model, data, feature, n_points = 50) {
  values <- seq(min(data[[feature]]), max(data[[feature]]),
               length.out = n_points)
  yhat <- vapply(values, function(v) {
    d <- data
```

```

    d[[feature]] <- v
    mean(predict(model, d))
  }, numeric(1))
  data.frame(x = values, yhat = yhat)
}

# PDP bidimensional. Igual idea sobre dos features simultáneas.
compute_pdp_2d <- function(model, data, f1, f2, n_points = 20) {
  v1 <- seq(min(data[[f1]]), max(data[[f1]]), length.out = n_points)
  v2 <- seq(min(data[[f2]]), max(data[[f2]]), length.out = n_points)
  grid <- expand.grid(v1 = v1, v2 = v2)
  names(grid) <- c(f1, f2)
  grid$yhat <- vapply(seq_len(nrow(grid)), function(i) {
    d <- data
    d[[f1]] <- grid[[f1]][i]
    d[[f2]] <- grid[[f2]][i]
    mean(predict(model, d))
  }, numeric(1))
  grid
}

```

2. Ejercicio 1 — PDP unidimensional: alquiler de bicicletas

2.1. Carga y preparación de datos

```
day <- read.csv("data/day.csv")

# La columna 'instant' es un índice secuencial diario que comienza en 1
# y corresponde al 1 de enero de 2011. Por tanto representa exactamente
# "días desde 2011".
day$days_since_2011 <- day$instant

# Variables que entrarán al Random Forest. Se incluyen tanto las
# que se analizarán mediante PDP como el resto de variables relevantes,
# para que el modelo disponga del contexto completo.
bike_features <- c("days_since_2011", "temp", "hum", "windspeed",
                  "season", "yr", "mnth", "holiday", "weekday",
                  "workingday", "weathersit")
bike_data <- day[, c(bike_features, "cnt")]

cat("Dimensiones del dataset:", nrow(bike_data), "x", ncol(bike_data), "\n")

## Dimensiones del dataset: 731 x 12
```

Nota sobre la escala de las variables. En el *Bike Sharing Dataset* original, temp, hum y windspeed están normalizadas en el rango [0, 1]: temp dividida entre 41 °C, hum entre 100 %, windspeed entre 67. Esta normalización se mantiene tal cual en los gráficos para preservar la coherencia con el dataset.

2.2. Entrenamiento del Random Forest

```
set.seed(42)
rf_bike <- randomForest(cnt ~ ., data = bike_data,
                        ntree = 500, importance = TRUE)

r2_bike <- 1 - rf_bike$mse[length(rf_bike$mse)] / var(bike_data$cnt)
cat("R² Out-Of-Bag:", round(r2_bike, 3), "\n")

## R² Out-Of-Bag: 0.892
```

El modelo alcanza un ajuste muy alto (R^2 OOB ≈ 0.892), lo que respalda la fiabilidad de los PDP calculados a continuación.

2.3. Cálculo de los PDP

```
pdp_days <- compute_pdp(rf_bike, bike_data, "days_since_2011")
pdp_temp <- compute_pdp(rf_bike, bike_data, "temp")
pdp_hum <- compute_pdp(rf_bike, bike_data, "hum")
pdp_wind <- compute_pdp(rf_bike, bike_data, "windspeed")
```

2.4. Visualización

```
plot_pdp <- function(pdp_df, rug, xlab, title) {  
  ggplot(pdp_df, aes(x = x, y = yhat)) +  
    geom_line(color = "#2166ac", linewidth = 1.1) +  
    geom_rug(data = data.frame(x = rug), aes(x = x),  
            sides = "b", alpha = 0.25,  
            length = unit(0.025, "npc"),  
            inherit.aes = FALSE) +  
    labs(title = title, x = xlab, y = "Predicción de cnt") +  
    theme_bw(base_size = 11) +  
    theme(plot.title = element_text(face = "bold", size = 11))  
}  
  
p1 <- plot_pdp(pdp_days, bike_data$days_since_2011,  
              "Días desde 2011", "Días desde 2011")  
p2 <- plot_pdp(pdp_temp, bike_data$temp,  
              "Temperatura (norm.)", "Temperatura")  
p3 <- plot_pdp(pdp_hum, bike_data$hum,  
              "Humedad (norm.)", "Humedad")  
p4 <- plot_pdp(pdp_wind, bike_data$windspeed,  
              "Velocidad del viento (norm.)", "Viento")  
  
grid.arrange(p1, p2, p3, p4, ncol = 2)
```




Figura 1: PDPs unidimensionales sobre el modelo de alquiler de bicicletas. La línea azul muestra el efecto marginal aprendido por el Random Forest; la alfombra inferior representa la distribución empírica de la variable correspondiente.

2.5. Análisis e interpretación

Días desde 2011. Se observa una **tendencia creciente clara y prácticamente monótona**: la predicción del número de alquileres pasa de unos ~3 000 a comienzos de 2011 hasta ~5 500 a finales de 2012. Este patrón refleja la **adopción progresiva del servicio de bike-sharing** a lo largo de esos dos años, un efecto temporal puro independiente del clima. La pendiente se atenúa hacia el final, lo que sugiere una **saturación parcial** del crecimiento.

Temperatura. Existe una relación **positiva no lineal con forma de campana asimétrica**: a partir de aproximadamente 0.15 ($\approx 6^\circ\text{C}$) los alquileres crecen rápidamente, alcanzan un **máximo en torno a 0.65–0.70** ($\approx 27\text{--}29^\circ\text{C}$), y descienden ligeramente en valores extremos. Esto coincide con la intuición: temperaturas demasiado frías o excesivamente cálidas desincentivan el uso de la bicicleta. La curva confirma que el modelo ha capturado un **óptimo térmico** y no una relación puramente lineal.

Humedad. La relación es **negativa**: la predicción se mantiene relativamente plana hasta valores de humedad cercanos a 0.6 y a partir de ahí **decrece de forma marcada**. Una humedad alta suele asociarse a días lluviosos o nublados, condiciones que disuaden a los usuarios. La densidad empírica se concentra en el rango 0.4–0.8, donde el efecto es más fiable.

Velocidad del viento. Efecto **negativo y aproximadamente monótono**: a más viento, menos alquileres. La caída más pronunciada aparece en el rango 0.1–0.4. Para valores superiores el efecto se atenúa, en parte porque la densidad de observaciones es muy baja (alfombra escasa) y el modelo extrapola con menor confianza.

3. Ejercicio 2 — PDP bidimensional: humedad y temperatura

3.1. Muestra aleatoria

El cálculo del PDP 2D requiere evaluar el modelo sobre $|grid_1| \times |grid_2| \times n$ filas. Para mantener el coste razonable se extrae una **muestra aleatoria** del dataset, tal y como recomienda el enunciado:

```
set.seed(42)
bike_sample <- bike_data[sample(nrow(bike_data), 300), ]
cat("Tamaño de la muestra:", nrow(bike_sample), "filas\n")
```

```
## Tamaño de la muestra: 300 filas
```

3.2. Cálculo del PDP 2D

```
pdp_2d <- compute_pdp_2d(rf_bike, bike_sample,
                        f1 = "hum", f2 = "temp",
                        n_points = 25)
```

3.3. Visualización

Para evitar huecos entre las celdas se calculan `width` y `height` a partir del paso del *grid*. La densidad empírica de `hum` y `temp` se superpone mediante `geom_rug()` en blanco sobre los ejes inferior e izquierdo, lo que indica las regiones donde el PDP es más fiable.

```
tile_w <- diff(range(pdp_2d$hum)) / 24
tile_h <- diff(range(pdp_2d$temp)) / 24

ggplot(pdp_2d, aes(x = hum, y = temp, fill = yhat)) +
  geom_tile(width = tile_w, height = tile_h) +
  geom_rug(data = bike_sample, aes(x = hum, y = temp),
           inherit.aes = FALSE,
           alpha = 0.5, color = "white",
           length = unit(0.02, "npc")) +
  scale_fill_viridis_c(option = "plasma",
                       name = "cnt\npredicho") +
  labs(title = "PDP 2D: Humedad x Temperatura",
       x = "Humedad (norm.)",
       y = "Temperatura (norm.)") +
  theme_bw(base_size = 11) +
  theme(plot.title = element_text(face = "bold"),
        legend.position = "right")
```





Figura 2: PDP bidimensional para la interacción humedad-temperatura. El color representa la predicción del Random Forest para el número de alquileres. Las marcas blancas en los ejes muestran la densidad empírica de cada variable.

3.4. Distribución de las variables

Como complemento al PDP, se muestra la distribución marginal conjunta de las dos variables. Esto permite identificar zonas del plano donde el modelo extrapola por escasez de datos.

```
ggplot(bike_data, aes(x = hum, y = temp)) +  
  geom_point(alpha = 0.4, color = "#2166ac", size = 1.4) +  
  geom_density_2d(color = "#b2182b", linewidth = 0.6) +  
  labs(title = "Distribución conjunta humedad-temperatura",  
        x = "Humedad (norm.)",  
        y = "Temperatura (norm.)") +  
  theme_bw(base_size = 11) +  
  theme(plot.title = element_text(face = "bold"))
```




Figura 3: Distribución empírica conjunta de humedad y temperatura en el dataset (puntos) con curvas de densidad 2D superpuestas.

3.5. Análisis e interpretación

El gráfico bidimensional confirma y enriquece las conclusiones obtenidas en los PDP 1D:

- La **predicción más alta** (zona amarilla brillante) se encuentra en la región de **temperatura alta** ($\sim 0.6\text{--}0.8$) y **humedad baja-moderada** ($\sim 0.3\text{--}0.6$): días cálidos pero secos, condiciones óptimas para usar la bicicleta.
- La **predicción más baja** (zona oscura) corresponde a la combinación de **temperatura baja y humedad alta**, es decir, días fríos y húmedos, típicamente invernales y desapacibles.
- La transición de color es **diagonal**, lo que sugiere una **interacción suave** entre ambas variables: el efecto positivo de la temperatura se ve **atenuado por una humedad elevada**, y el efecto negativo de la humedad se compensa parcialmente con buenas temperaturas.
- En las **zonas con escasa densidad empírica** (esquina superior izquierda: temperatura muy alta y humedad muy baja; esquina inferior derecha: temperatura muy baja y humedad muy alta) las predicciones del PDP deben interpretarse con cautela, ya que el modelo extrapola sobre combinaciones poco representadas en los datos. Esta es precisamente la limitación que advierte la teoría del PDP cuando hay correlación entre variables.

4. Ejercicio 3 — PDP: predicción del precio de viviendas

4.1. Carga y muestreo aleatorio

El dataset `kc_house_data.csv` contiene unas 21 000 viviendas. Para que el cálculo del PDP sea tratable se trabaja con una **muestra aleatoria de 1 000 observaciones**, tanto para entrenar el modelo como para evaluar el PDP:

```
house <- read.csv("data/kc_house_data.csv")
cat("Dataset original:", nrow(house), "filas\n")

## Dataset original: 21613 filas

set.seed(42)
house_sample <- house[sample(nrow(house), 1000), ]

# Las 6 features especificadas en el enunciado.
house_features <- c("bedrooms", "bathrooms", "sqft_living",
                   "sqft_lot", "floors", "yr_built")
house_data <- house_sample[, c(house_features, "price")]

cat("Muestra usada:", nrow(house_data), "filas\n")
```

```
## Muestra usada: 1000 filas
```

```
summary(house_data$price)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  89950   314750  449975   531884  627000 3300000
```

4.2. Entrenamiento del Random Forest

```
set.seed(42)
rf_house <- randomForest(price ~ ., data = house_data,
                          ntree = 500, importance = TRUE)

r2_house <- 1 - rf_house$mse[length(rf_house$mse)] / var(house_data$price)
cat("R² Out-Of-Bag:", round(r2_house, 3), "\n")
```

```
## R² Out-Of-Bag: 0.563
```

El modelo explica aproximadamente el 56.3% de la varianza del precio sobre datos no vistos (validación *out-of-bag*), un resultado razonable considerando que sólo se utilizan 6 variables del total disponible y una muestra reducida.

4.3. Cálculo de los PDP

```

pdp_bedrooms <- compute_pdp(rf_house, house_data, "bedrooms")
pdp_bathrooms <- compute_pdp(rf_house, house_data, "bathrooms")
pdp_sqftliv <- compute_pdp(rf_house, house_data, "sqft_living")
pdp_floors <- compute_pdp(rf_house, house_data, "floors")

```

4.4. Visualización

```

plot_pdp_house <- function(pdp_df, rug, xlab, title) {
  ggplot(pdp_df, aes(x = x, y = yhat)) +
    geom_line(color = "#b2182b", linewidth = 1.1) +
    geom_rug(data = data.frame(x = rug), aes(x = x),
             sides = "b", alpha = 0.25,
             length = unit(0.025, "npc"),
             inherit.aes = FALSE) +
    scale_y_continuous(labels = function(v) paste0("$", format(v / 1000, big.mark = ",", trim = TRUE)),
                       labs(title = title, x = xlab, y = "Precio predicho") +
    theme_bw(base_size = 11) +
    theme(plot.title = element_text(face = "bold", size = 11))
}

q1 <- plot_pdp_house(pdp_bedrooms, house_data$bedrooms,
                    "Bedrooms", "Habitaciones")
q2 <- plot_pdp_house(pdp_bathrooms, house_data$bathrooms,
                    "Bathrooms", "Baños")
q3 <- plot_pdp_house(pdp_sqftliv, house_data$sqft_living,
                    "Sqft living", "Superficie habitable (sqft)")
q4 <- plot_pdp_house(pdp_floors, house_data$floors,
                    "Floors", "Plantas")

grid.arrange(q1, q2, q3, q4, ncol = 2)

```




Figura 4: PDPs unidimensionales para la predicción del precio. El eje vertical está expresado en dólares estadounidenses.

4.5. Análisis e interpretación

Habitaciones (bedrooms). El efecto es **positivo pero claramente decreciente**: añadir habitaciones aumenta el precio sólo hasta un punto (3–5 habitaciones), donde la curva se estabiliza o incluso decae ligeramente. Esto es coherente con el mercado inmobiliario: a igualdad de superficie, demasiadas habitaciones implican estancias más pequeñas, lo que **deja de aportar valor**. Además, la densidad empírica está concentrada en 2–5 habitaciones, por lo que los extremos del eje son menos fiables.

Baños (bathrooms). Relación **positiva y aproximadamente monótona**, más pronunciada que la de las habitaciones. Cada baño adicional aporta un incremento sostenido al precio, especialmente en el rango 1.5–4. Los baños son un indicador claro de **gama y comodidad** de la vivienda, lo que justifica este comportamiento.

Superficie habitable (sqft_living). Es la variable con **mayor influencia**, con una relación **positiva, fuerte y casi lineal** en el rango central. La pendiente se atenúa en valores muy altos ($> 6\,000$ sqft), donde el mercado se vuelve muy específico y el modelo dispone de pocas observaciones. Este resultado coincide con la intuición económica de que el precio se determina en gran medida por el tamaño de la vivienda.

Plantas (floors). Efecto **positivo pero modesto**: pasar de una a dos plantas incrementa el precio de manera apreciable, pero más allá la ganancia es pequeña. Hay que tener en cuenta que la variable toma

sólo unos pocos valores discretos (1, 1.5, 2, 2.5, 3, 3.5), por lo que el PDP entre esos valores es producto de interpolación más que de un comportamiento real del modelo.

5. Conclusiones generales

A lo largo de la práctica se ha aplicado el método **Partial Dependency Plot** a dos modelos *Random Forest*, ilustrando su utilidad como herramienta de XAI *model-agnostic*:

1. **Interpretación 1D (bicicletas)**. Los PDP revelaron patrones claros y coherentes: un crecimiento sostenido de la demanda en el tiempo, un óptimo térmico en torno a los 28 °C, y efectos disuasorios de la humedad y el viento. Esto demuestra que el Random Forest captura estructura no lineal sin necesidad de definir transformaciones manuales.
2. **Interacción 2D (bicicletas)**. El PDP bidimensional *humedad × temperatura* reveló un **efecto multiplicativo y no aditivo**: la combinación más favorable (temperatura alta + humedad baja) dispara la predicción, mientras que la combinación contraria la deprime fuertemente. La distribución empírica conjunta evidenció también las **zonas en las que el PDP debe interpretarse con prudencia**, dado que el modelo extrapola fuera del soporte real.
3. **Interpretación 1D (viviendas)**. El análisis del precio mostró que *sqft_living* es la variable dominante, mientras que *bedrooms* muestra **rendimientos decrecientes** y *floors* un efecto modesto. Estos resultados encajan con la intuición económica del sector inmobiliario y refuerzan la confianza en el modelo.

Limitaciones reconocidas. El PDP representa el efecto **promedio**: no recoge la heterogeneidad entre instancias (efectos individuales) ni distingue interacciones no incluidas en el subconjunto x_S . Para complementar el análisis sería razonable utilizar herramientas como **ICE plots**, **ALE plots** (que mitigan el problema de la dependencia entre variables) o valores **SHAP**.

6. Información de la sesión

```
## R version 4.5.2 (2025-10-31 ucrt)
## Platform: x86_64-w64-mingw32/x64
## Running under: Windows 11 x64 (build 26200)
##
## Matrix products: default
##   LAPACK version 3.12.1
##
## locale:
## [1] LC_COLLATE=Spanish_Spain.utf8  LC_CTYPE=Spanish_Spain.utf8
## [3] LC_MONETARY=Spanish_Spain.utf8 LC_NUMERIC=C
## [5] LC_TIME=Spanish_Spain.utf8
##
## time zone: Europe/Madrid
## tzcode source: internal
##
## attached base packages:
## [1] stats      graphics  grDevices  utils      datasets  methods   base
##
## other attached packages:
## [1] viridis_0.6.5      viridisLite_0.4.2  gridExtra_2.3
## [4] dplyr_1.1.4        ggplot2_4.0.1      randomForest_4.7-1.2
##
## loaded via a namespace (and not attached):
## [1] gtable_0.3.6      compiler_4.5.2     tidyselect_1.2.1   scales_1.4.0
```

## [5]	yaml_2.3.12	fastmap_1.2.0	R6_2.6.1	labeling_0.4.3
## [9]	generics_0.1.4	isoband_0.3.0	knitr_1.51	MASS_7.3-65
## [13]	tibble_3.3.0	pillar_1.11.1	RColorBrewer_1.1-3	rlang_1.1.6
## [17]	xfun_0.55	S7_0.2.1	otel_0.2.0	cli_3.6.5
## [21]	withr_3.0.2	magrittr_2.0.4	digest_0.6.39	grid_4.5.2
## [25]	lifecycle_1.0.5	vctrs_0.6.5	evaluate_1.0.5	glue_1.8.0
## [29]	farver_2.1.2	codetools_0.2-20	rmarkdown_2.30	tools_4.5.2
## [33]	pkgconfig_2.0.3	htmltools_0.5.9		